

上海科技大学 GenAI API 服务使用手册

目 录

1 GenAI API 服务介绍	1
2 模型介绍	1
2.1 GPT-5.4 模型接口	1
2.2 GPT-5.3-Codex 模型接口	1
2.3 DeepSeek-R1 模型接口	1
2.4 DeepSeek-V3.2 模型接口	2
2.5 Qwen-instruct 模型接口	2
2.6 DeepSeek-Math-V2 模型接口	3
2.7 Qwen-code 模型接口	3
2.8 BGE-M3 嵌入模型接口	3
2.9 bge-reranker-v2-m3 重排序模型接口	3
2.10 Stable Diffusion 的运行环境	4
3 访问方式	4
3.1 模型调用接口	4
3.2 访问信息的获取	4
4 接口调用示例	5
4.1 cURL 调用示例	5
4.1.1 流式调用:	5
4.1.2 多模态调用（图像理解）	5
4.2 Python 调用示例	5
4.2.1 基础对话	5
4.2.2 流式对话	6
4.2.3 流式对话	6
4.2.4 多模态调用（图像理解）	7
4.2.5 多模态调用限制	9
4.3 OpenClaw 配置示例	9

* 图书信息中心更新于 2026 年 3 月。

4.4 Stable Diffusion 环境的访问.....	10
5 常见人工智能应用架构	10
5.1 基于提示词工程的对话应用.....	10
5.2 检索增强生成知识库（RAG）应用.....	11
5.3 智能助手类应用（Agent）	11
附录：模型选型指南	11

1 GenAI API 服务介绍

在教学、科研、办公等场景中实施人工智能应用时，开发与部署这些应用通常需要调用特定的人工智能模型接口或者使用特定的运行环境。

上海科技大学面向校内用户推出了 GenAI API 服务，集中提供对包括 GPT-5.4、GPT-5.3-Codex、DeepSeek-R1、DeepSeek-V3、Qwen3、Qwen-code 等模型接口的便捷访问，并配备 Stable Diffusion 模型的运行环境，以满足用户对高级人工智能资源的需求。

2 模型介绍

2.1 GPT-5.4 模型接口

GPT-5.4 是 OpenAI 于 2026 年 3 月 5 日正式发布的最新旗舰模型，官方将其定义为“迄今能力最强、效率最高的专业工作前沿模型”。这是 OpenAI 首次将前沿推理、编码与智能体能力整合至单一模型，深度融合了 GPT-5.3-Codex 的编码能力，并首次引入原生电脑操控能力（Native Computer Use），标志着 AI 从“被动响应”正式迈向“主动执行”的智能体新阶段。在 OSWorld-Verified 测试中以 75.0% 的成功率历史性地超越人类专家平均水平；在 BrowseComp 基准上，GPT-5.4 Pro 更是创下 89.3% 的新高。

上海科技大学提供的 GPT-5.4 模型接口采用 Azure OpenAI 服务，经评估审核通过后，可提供对应接口访问。

2.2 GPT-5.3-Codex 模型接口

GPT-5.3-Codex 是 OpenAI 于 2026 年 2 月 5 日正式发布的最新编程专用模型，官方称其为“迄今最强编程代理”。该模型在 GPT-5.2-Codex 编码性能基础上，融合了 GPT-5.2 的推理与专业知识能力，实现性能双飞跃：完成同等任务所需 token 量较前代减少超一半，单 token 处理速度提升超 25%。在 SWE-bench Pro 测试中得分 56.8%；在 Terminal-Bench 2.0 测试中，从前代的 64.0% 大幅跃升至 77%。GPT-5.3-Codex 是 OpenAI 首个“深度参与自身开发”的模型，也是首个网络安全能力被评为“高等级”的模型，专门训练用于识别软件漏洞。

GPT-5.3-Codex 模型接口采用 Azure OpenAI 服务，适合承担需要长时间运行的复杂编程任务，如深度调研、自主调用工具以及端到端的流程执行。

2.3 DeepSeek-R1 模型接口

DeepSeek-R1 模型接口目前实际运行的是 **DeepSeek-R1-0528**，为 DeepSeek 推出的推理旗舰模型升级版。该模型于 2025 年 5 月 28 日发布，以 DeepSeek V3 Base 为基座，参数量达 685B（其中 14B 为 MTP 层）。通过强化推理链等优化，其推理、编程能力显著提升，在 AIME 2025 数学测试中准确率从 70% 跃升至 87.5%。该模型还支持 JSON 输出，幻觉率降低约 50%，性能可媲美美国国际顶尖推理模型。

经评估审核通过后，提供校内本地部署的 DeepSeek-R1 模型，适用于复杂逻辑推理与问题

求解、数学证明与科学计算、代码生成与算法设计以及学术研究与论文辅助。

2.4 DeepSeek-V3.2 模型接口

DeepSeek-V3.2 模型接口目前实际运行的是 **DeepSeek-V3.2**，为 DeepSeek 于 2025 年 12 月 1 日发布的通用旗舰模型，该模型参数达 685B，首次在开源模型中实现“思考模式下工具调用”——AI 可在多轮推理中边思考、边调用外部工具，再根据结果修正策略，形成完整执行闭环。在 SWE-Bench Verified、BrowseComp、Tool-Decathlon 等权威 Agent 评测中表现优异，擅长中英双语对话、文档理解、知识问答，支持 128K 超长上下文。

经评估审核通过后，提供校内本地部署的 DeepSeek-V3.2 模型，适合长文档处理与摘要生成、多轮对话与知识问答、内容创作与文案撰写以及中英双语翻译与润色。

2.5 Qwen-instruct 模型接口

Qwen-instruct 模型接口（与 Qwen-instruct-VL 模型接口合并）实际运行的是 **Qwen3.5-397B-A17B**，为阿里巴巴通义千问团队于 2026 年 2 月 16 日发布的新一代开源旗舰模型。该模型采用创新的混合架构，将线性注意力与稀疏 MoE 相结合，总参数达 397B，每次推理仅激活 17B 参数，实现性能与效率的精妙平衡。与上代模型 Qwen3-235B-A22B 相比，32K 和 256K 上下文长度下的解码吞吐量提升显著。该模型定位“为智能体时代而生”，基座性能与闭源的 Qwen3-Max 持平，支持文本和多模态任务。

经评估审核通过后，提供基于 Qwen3.5-397B-A17B 模型的 API 访问，适用于多语言对话与翻译、代码生成与程序开发、指令遵循与任务执行以及智能体应用与工作流自动化。

Qwen3.5 支持两种模式，官方推荐调用参数如下：

(1) 思考模式 (Thinking Mode)：

1. temperature: 0.6
2. top_p: 0.95
3. top_k: 20
4. min_p: 0.0
5. presence_penalty: 0.0
6. repetition_penalty: 1.0

(2) 非思考模式 (Non-Thinking Mode)：

1. temperature: 0.7
2. top_p: 0.8
3. top_k: 20
4. min_p: 0.0
5. presence_penalty: 1.5
6. repetition_penalty: 1.0

(3) 非思考模式调用示例：

1. payload = {
2. "model": "qwen-instruct",

```
3.     "messages": [...],
4.     "temperature": 0.7,
5.     "top_p": 0.8,
6.     "top_k": 20,
7.     "presence_penalty": 1.5,
8.     "repetition_penalty": 1.0
9. }
```

2.6 DeepSeek-Math-V2 模型接口

DeepSeek-Math-V2 模型接口目前实际运行的是 **DeepSeek-Math-V2**，为 DeepSeek 于 2025 年 11 月 27 日发布的数学专用模型。该模型参数达 685B，是业内首个达到国际奥林匹克数学竞赛（IMO）金牌水平且全面开源的数学模型。DeepSeek-Math-V2 专注于定理证明和自我验证能力，在 IMO 2025 和 CMO 2024 上取得金牌级成绩，Putnam 2024 以扩展测试计算实现 118/120（接近满分）。该模型构建在 DeepSeek-V3.2-Exp-Base 之上，注重推理过程的严谨性和完整性。

经评估审核通过后，提供基于 DeepSeek-Math-V2 模型的 API 访问，适合公式推导与符号计算、数学证明与逻辑推理、科学计算与工程分析或教育辅导与习题解答。

2.7 Qwen-code 模型接口

Qwen-code 模型接口目前实际运行的是 **Qwen3-Coder-Next**，为阿里巴巴通义千问团队于 2026 年 2 月 4 日发布的编程专用模型。该模型采用极致高效的 MoE 架构，总参数达 80B，每次推理仅激活 3B 参数，大幅降低了显存与算力需求。Qwen3-Coder-Next 专为编程智能体设计，聚焦于长时程、多工具、可交互的真实编程任务，擅长代码生成、调试优化、代码审查等场景，编程能力出色，超过 Claude 3.7 接近 Claude 4 的水平。

经评估审核通过后，提供基于 Qwen3-Coder-Next 模型的 API 访问，适合代码生成与程序开发、代码调试与优化、代码审查与重构或编程智能体与自动化开发。

2.8 BGE-M3 嵌入模型接口

BGE-M3 模型接口目前实际运行的是 **BGE-M3**，为北京智源人工智能研究院（BAAI）于 2024 年 2 月发布的第三代通用嵌入模型。该模型支持超过 100 种语言，具备多语言、跨语言检索能力，一站式集成了稠密检索（Dense）、稀疏检索（Sparse）、多向量检索（Multi-Vector）三种检索功能。BGE-M3 最大输入长度为 8192 token，多次刷新 BEIR、MTEB、C-MTEB 等评测榜单，成为首个中国国产 AI 模型。全球下载量超过 1500 万。

经评估审核通过后，提供基于 BGE-M3 模型的 API 访问，适合用于 RAG 向量数据库构建，对文档的语义检索与文档搜索、文档聚类与分类或语义相似度计算。

2.9 bge-reranker-v2-m3 重排序模型接口

bge-reranker-v2-m3 模型接口目前实际运行的是 **bge-reranker-v2-m3**，为北京智源人工智能研究院（BAAI）发布的检索重排序模型。该模型专为检索结果精排优化，配合 BGE-M3 使

用可显著提升 RAG 检索精度。bge-reranker-v2-m3 支持多语言场景，能够对初检结果进行相关性重排序，帮助搜索系统、问答系统、推荐系统获得更精准的结果排序。

经评估审核通过后，提供基于 bge-reranker-v2-m3 模型的 API 访问，适合用于 RAG 检索精度优化，对文档搜索结果重排序、问答系统答案排序或推荐系统结果优化。

2.10 Stable Diffusion 的运行环境

Stable Diffusion 是一种基于潜在扩散模型的文本生成图像技术，由 CompVis、Stability AI 和 LAION 联合开发。它能够将文本描述转化为高质量图像，广泛应用于虚拟角色设计、商品建模和艺术创作等领域。

学校通过 ComfyUI 环境向用户提供 Stable Diffusion 服务（非 API）。ComfyUI 是一个基于节点的可视化工作流框架，相较于传统 WebUI 具有以下优势：

- (1) 节点式工作流：通过拖拽节点构建图像生成流程，直观灵活。
- (2) 可视化编程：支持复杂工作流设计，便于调试和优化。
- (3) 高效资源管理：支持模型缓存、显存优化，提升生成效率。
- (4) 扩展生态：丰富的自定义节点和插件，支持 ControlNet、AnimateDiff 等高级功能。
- (5) 工作流复用：可保存、分享和复用完整工作流配置。

经评估审核通过后，学校提供基于 ComfyUI 的 Stable Diffusion 运行环境访问，适用于图像编辑与风格迁移、创意设计、自动化内容生成等场景。

3 访问方式

在资源有限的条件下，为促进资源充分、合理和合规使用，上海科技大学 GenAI API 服务采用申请评估机制，且仅限校内访问。申请者在获得所在院所/部门、图书信息中心的评估审核通过后，服务将向申请者开放使用。

3.1 模型调用接口

经评估审核通过后，由图书信息中心负责协调运行模型所需环境的构建，并向用户提供接口（API）的具体信息，接口采用与 OpenAI 兼容的 API，所以可以将提供的接口当成 OpenAI 的本地替代。

3.2 访问信息的获取

评估审核通过后，用户可通过[上海科技大学 GenAI](https://genaiapi.shanghaitech.edu.cn/api/v1/start) 平台的 API Key 管理界面获取模型接入信息。

接口统一为：<https://genaiapi.shanghaitech.edu.cn/api/v1/start>

4 接口调用示例

4.1 cURL 调用示例

4.1.1 流式调用:

```
1. curl -X POST https://genaiapi.shanghaitech.edu.cn/api/v1/start \
2.   -H "Content-Type: application/json" \
3.   -H "Authorization: Bearer YOUR_API_KEY" \
4.   -d '{
5.     "stream": true,
6.     "messages": [
7.       {"role": "system", "content": "You are a helpful assistant."},
8.       {"role": "user", "content": "你好, 请介绍一下自己。"}
9.     ]
10.  }'
```

4.1.2 多模态调用 (图像理解)

```
1. curl -X POST https://genaiapi.shanghaitech.edu.cn/api/v1/start \
2.   -H "Content-Type: application/json" \
3.   -H "Authorization: Bearer YOUR_API_KEY" \
4.   -d '{
5.     "stream": false,
6.     "model": "qwen2.5-vl-instruct",
7.     "messages": [
8.       {
9.         "role": "user",
10.        "content": [
11.          {"type": "text", "text": "请描述这张图片的内容"},
12.          {"type": "image_url", "image_url": {"url": "https://example.com/image.jpg"}}
13.        ]
14.      }
15.    ]
16.  }'
```

4.2 Python 调用示例

4.2.1 基础对话

```
1. import requests
2.
3. API_URL = "https://genaiapi.shanghaitech.edu.cn/api/v1/start"
4. API_KEY = "YOUR_API_KEY" # 替换为您的 API Key
5.
6. headers = {
7.     "Content-Type": "application/json",
8.     "Authorization": f"Bearer {API_KEY}"
9. }
10.
```

```
11. # 通用对话示例
12. payload = {
13.     "stream": False,
14.     "messages": [
15.         {"role": "system", "content": "You are a helpful assistant."},
16.         {"role": "user", "content": "你好, 请介绍一下自己"}
17.     ]
18. }
19.
20. response = requests.post(API_URL, headers=headers, json=payload)
21. print(response.json())
```

4.2.2 流式对话

```
1. import requests
2.
3. API_URL = "https://genaiapi.shanghaitech.edu.cn/api/v1/start"
4. API_KEY = "YOUR_API_KEY"
5.
6. headers = {
7.     "Content-Type": "application/json",
8.     "Authorization": f"Bearer {API_KEY}"
9. }
10.
11. payload = {
12.     "stream": True,
13.     "messages": [
14.         {"role": "user", "content": "请解释什么是机器学习"}
15.     ]
16. }
17.
18. response = requests.post(API_URL, headers=headers, json=payload, stream=True)
19. for line in response.iter_lines():
20.     if line:
21.         print(line.decode("utf-8"))
```

4.2.3 流式对话

```
1. import requests
2.
3. API_URL = "https://genaiapi.shanghaitech.edu.cn/api/v1/start"
4. API_KEY = "YOUR_API_KEY"
5.
6. headers = {
7.     "Content-Type": "application/json",
8.     "Authorization": f"Bearer {API_KEY}"
9. }
10.
11. # 调用 DeepSeek-R1-0528 推理模型
```

```
12. payload = {
13.     "stream": False,
14.     "model": "deepseek-r1:671b",
15.     "messages": [
16.         {"role": "user", "content": "请证明：根号 2 是无理数"}
17.     ]
18. }
19. response = requests.post(API_URL, headers=headers, json=payload)
20. print(response.json())
21.
22. # 调用 Qwen-code 编程模型
23. payload = {
24.     "stream": False,
25.     "model": "qwen-code",
26.     "messages": [
27.         {"role": "user", "content": "请用 Python 实现一个二叉树的前序遍历"}
28.     ]
29. }
30. response = requests.post(API_URL, headers=headers, json=payload)
31. print(response.json())
32.
33. # 调用 DeepSeek-Math-V2 数学模型
34. payload = {
35.     "stream": False,
36.     "model": "deepseek-math",
37.     "messages": [
38.         {"role": "user", "content": "求解积分  $\int (x^2+2x+1) dx$ "}
39.     ]
40. }
41. response = requests.post(API_URL, headers=headers, json=payload)
42. print(response.json())
```

4.2.4 多模态调用（图像理解）

```
1. import requests
2. import base64
3.
4. API_URL = "https://genaiapi.shanghaitech.edu.cn/api/v1/start"
5. API_KEY = "YOUR_API_KEY"
6.
7. headers = {
8.     "Content-Type": "application/json",
9.     "Authorization": f"Bearer {API_KEY}"
10. }
11.
12. # 方式一：通过图片 URL
13. payload = {
14.     "stream": False,
```

```

15.     "model": "qwen2.5-vl-instruct", # 或 qwen-instruct
16.     "messages": [
17.         {
18.             "role": "user",
19.             "content": [
20.                 {"type": "text", "text": "请描述这张图片的内容"},
21.                 {"type": "image_url", "image_url": {"url": "https://example.com/image.jpg"}}
22.             ]
23.         }
24.     ]
25. }
26. response = requests.post(API_URL, headers=headers, json=payload)
27. print(response.json())
28.
29. # 方式二：通过 Base64 编码的本地图片
30. with open("local_image.jpg", "rb") as f:
31.     image_base64 = base64.b64encode(f.read()).decode("utf-8")
32.
33. payload = {
34.     "stream": False,
35.     "model": "qwen2.5-vl-instruct",
36.     "messages": [
37.         {
38.             "role": "user",
39.             "content": [
40.                 {"type": "text", "text": "这张图片里有什么?"},
41.                 {"type": "image_url", "image_url": {"url":
42. f"data:image/jpeg;base64,{image_base64}"}}
43.             ]
44.         }
45.     ]
46. }
47. response = requests.post(API_URL, headers=headers, json=payload)
48. print(response.json())
49.
50. # 方式三：视频理解
51. payload = {
52.     "stream": False,
53.     "model": "qwen2.5-vl-instruct",
54.     "messages": [
55.         {
56.             "role": "user",
57.             "content": [
58.                 {"type": "text", "text": "请分析这段视频的内容"},
59.                 {"type": "video_url", "video_url": {"url": "https://example.com/video.mp4"}}
60.             ]
61.         }

```

```

61.     ]
62. }
63. response = requests.post(API_URL, headers=headers, json=payload)
64. print(response.json())

```

4.2.5 多模态调用限制

限制项	说明
单次最大图片数	10 张
单张图片大小 (URL)	≤ 10 MB
单张图片大小 (Base64)	≤ 10 MB
视频文件大小 (URL)	≤ 2 GB
图片格式	JPEG、PNG、BMP、GIF、WebP
图片 URL 要求	公开可访问, 无需登录、无防盗链、无 IP 限制

注意：**本地模型服务**仅限校内访问。如通过图片 URL 调用，需确保 URL 可在校园网内访问，或使用 Base64 编码方式传入本地图片。

4.3 OpenClaw 配置示例

OpenClaw 是一个本地 AI Agent 运行框架，支持配置多种模型后端。用户可在 `openclaw/openclaw.json` 中配置 GenAI API 网关。

配置示例：

```

1. {
2.   "providers": {
3.     "genai": {
4.       "type": "openai-compatible",
5.       "baseUrl": "https://genaiapi.shanghaitech.edu.cn/api/v1",
6.       "apiKey": "YOUR_API_KEY",
7.       "models": {
8.         "gpt-5.4": {
9.           "name": "GPT-5.4",
10.          "context": 128000
11.        },
12.        "gpt-5.3-codex": {
13.          "name": "GPT-5.3-Codex",
14.          "context": 128000
15.        },
16.        "deepseek-r1:671b": {
17.          "name": "DeepSeek-R1-0528",
18.          "context": 65536
19.        },
20.        "deepseek-v3:671b": {
21.          "name": "DeepSeek-V3.2",
22.          "context": 131072
23.        },
24.        "qwen-instruct": {

```

```
25.         "name": "Qwen3.5-397B-A17B",
26.         "context": 262144
27.     },
28.     "qwen2.5-vl-instruct": {
29.         "name": "Qwen3.5-397B-A17B",
30.         "context": 262144
31.     },
32.     "qwen-code": {
33.         "name": "Qwen3-Coder-Next",
34.         "context": 262144
35.     },
36.     "deepseek-math": {
37.         "name": "DeepSeek-Math-V2",
38.         "context": 163840
39.     }
40. }
41. }
42. },
43. "modelAliases": {
44.     "r1": "deepseek-r1:671b",
45.     "v3": "deepseek-v3:671b",
46.     "qwen": "qwen-instruct",
47.     "coder": "qwen-code",
48.     "math": "deepseek-math",
49.     "gpt": "gpt-5.4"
50. }
51. }
```

配置完成后，需要重启 OpenClaw 的 Gateway 后，可通过别名或完整模型 ID 调用相应模型。

4.4 Stable Diffusion 环境的访问

经评估审核通过后，用户将通过邮件获取 ComfyUI 的 Web URL，可直接通过浏览器访问使用。

注意：

- (1) 如需使用自定义 LoRA 模型文件，请在申请时提前沟通提供。
- (2) 因资源有限，服务采用分时共享方式，高峰期可能出现排队等待。

5 常见人工智能应用架构

5.1 基于提示词工程的对话应用

提示词(Prompts)是一段人类可读的文本，它被输入到大语言模型或其他人工智能系统中，以获得特定的输出或完成某个任务。简单来说，它是一个指令或问题，用于引导人工智能系统按照我们的意图产生所需的响应。

基于提示词（Prompts），快速交付简单的 Web APP 工具，是最简单的人工智能应用交付方式，大致可参考如下步骤进行尝试：

- (1) 确定应用场景和功能需求。
- (2) 设计并测试 Prompts 与模型参数。
- (3) 编排 Prompts 与用户输入。
- (4) 发布应用。
- (5) 观测并持续迭代。

生成型应用与对话型应用在提示词编排上略有差异，对话型应用需结合“对话生命周期”来满足更复杂的用户情景和上下文管理需求。

5.2 检索增强生成知识库（RAG）应用

基于检索增强生成的知识库（Retrieval Augmented Generation, RAG）以向量检索（Vector Retrieval）为核心，是解决对话模型获取外部知识和缓解幻觉问题的主要解决方案。

使用该技术可经济且高效地构建基于生成式人工智能驱动的客服机器人、专业知识库、人工智能搜索引擎等应用。

RAG 典型架构：

- (1) 文档嵌入：使用 BGE-M3 将知识库文档转换为向量。
- (2) 相似度检索：根据用户查询检索最相关的文档片段。
- (3) 结果重排：使用 bge-reranker-v2-m3 优化检索结果排序。
- (4) 答案生成：将检索结果作为上下文，调用 Qwen3.5-397B-A17B 或 DeepSeek-V3.2 生成回答。

5.3 智能助手类应用（Agent）

智能助手（Agent Assistant）应用利用大语言模型的推理能力，能够自主对复杂的人类任务进行目标规划、任务拆解、工具调用、过程迭代，并在没有人类干预的情况下完成任务。

用户可以通过“提示词”编写智能助手指令。为了能够达到更优的预期效果，也可以在指令中明确任务目标、工作流程、资源和限制等。

- (1) **通用智能助手：** GPT-5.4、DeepSeek-V3.2、Qwen3.5-397B-A17B 等模型具备强大的推理和工具调用能力，适合构建通用型智能助手，能够处理多样化的任务场景。
- (2) **编程智能助手：** GPT-5.3-Codex 和 Qwen3-Coder-Next 专为编程智能体设计，能够承担长时间运行的复杂编程任务，支持深度调研、自主调用工具、端到端流程执行，适合构建软件开发自动化助手。

附录：模型选型指南

任务类型	任务类型	Model ID
通用对话与问答	GPT-5.4	GPT-5.4
	DeepSeek-V3.2	deepseek-v3:671b

	Qwen3.5-397B-A17B	qwen-instruct
复杂推理与数学	DeepSeek-R1-0528	deepseek-r1:671b
	DeepSeek-Math-V2	deepseek-math
代码生成与调试	GPT-5.3-Codex	gpt-5.3-codex
	Qwen3-Coder-Next	qwen-code
	Qwen3.5-397B-A17B	qwen-instruct
	DeepSeek-R1-0528	deepseek-r1:671b
图像理解与 OCR	Qwen3.5-397B-A17B	qwen-instruct
语义检索与 RAG	BGE-M3	bge-m3
	bge-reranker-v2-m3	bge-reranker
长文档处理	DeepSeek-V3.2	deepseek-v3:671b
	Qwen3.5-397B-A17B	qwen-instruct

注：平台根据模型发展，会持续跟进，以正式发布的模型相关说明为准。